

ЛАБОРАТОРНАЯ РАБОТА № 6

Моделирование таблиц Cassandra от запросов

Дисциплина: «Проектирование и применение NoSQL-технологий»

Образовательная программа: «Информационные системы» • 3 курс • 2 академических часа • индивидуально

Связанная лекция № 6: «Wide-column модель, partition key, clustering key»

Основная технология: Apache Cassandra • cqlsh / Docker

1. Цель работы

Сформировать практические навыки query-driven проектирования wide-column модели Apache Cassandra: от анализа пользовательских запросов и нагрузки к выбору partition key и clustering columns, созданию таблиц CQL и проверке того, что ключевые запросы выполняются без сканирования всего набора данных.

2. Результаты обучения

- анализирует паттерны чтения и записи предметной области;
- проектирует таблицы Cassandra от конкретных запросов;
- выбирает partition key с учетом распределения нагрузки;
- задает clustering columns для требуемого порядка и диапазонных выборок;
- создает keyspace и таблицы с помощью CQL;
- загружает и проверяет учебные данные;
- оценивает риск больших и горячих партиций и обосновывает денормализацию.

3. Необходимые знания

Перед занятием повторить: wide-column модель, keyspace, table, primary key, partition key, clustering column, партиция, денормализация, query-driven design, паттерны доступа, согласованность и базовый синтаксис CQL.

4. Оборудование и ПО

Apache Cassandra актуальной стабильной ветки, cqlsh, Docker Desktop или локальная установка. Для лабораторной работы достаточно одного учебного узла; кластеризация и эксплуатация многоузлового кластера не являются целью занятия.

```
docker run --name cassandra-lab6 -p 127.0.0.1:9042:9042 -d cassandra:5.0
```

После запуска дождитесь готовности Cassandra и подключитесь:

```
docker exec -it cassandra-lab6 cqlsh
SELECT release_version FROM system.local;
```

5. Правила безопасности

- использовать только искусственные учебные данные;
- не публиковать пароли и строки подключения;
- не открывать порт 9042 во внешнюю сеть без необходимости;
- не применять DROP/TRUNCATE к рабочим системам;
- перед DELETE проверять полный ключ удаляемой записи;
- не использовать ALLOW FILTERING как замену корректному моделированию;
- не создавать неограниченно растущие партиции.

6. Краткие теоретические сведения

6.1. Проектирование от запросов (query-driven design)

В Cassandra таблица проектируется прежде всего под заранее известный запрос. Вместо построения одной нормализованной универсальной схемы часто создают несколько денормализованных таблиц, каждая из которых эффективно обслуживает конкретный паттерн доступа. Поэтому сначала фиксируют запросы, затем определяют ключи и только после этого создают таблицы.

6.2. Partition key

Partition key определяет, в какую партицию попадает строка и как данные распределяются по узлам. Хороший partition key должен поддерживать нужный запрос и достаточно равномерно распределять нагрузку. Слишком популярное значение способно создать hot partition; слишком широкая партиция может неограниченно расти.

6.3. Clustering columns

Clustering columns задают порядок строк внутри одной партиции и позволяют эффективно выполнять диапазонные выборки после указания partition key. Порядок clustering columns является частью физической модели и должен следовать паттернам запросов.

6.4. PRIMARY KEY

В CQL запись PRIMARY KEY ((group_id), lesson_date, lesson_time) означает: group_id - partition key, а lesson_date и lesson_time - clustering columns. Все строки одной группы попадают в одну логическую партицию и упорядочиваются по указанным clustering columns.

```
PRIMARY KEY ((group_id), lesson_date, lesson_time)
```

6.5. Денормализация

Если приложению нужны разные способы чтения одних и тех же данных, Cassandra часто требует отдельных таблиц. Дублирование здесь является осознанным компромиссом ради предсказуемых запросов. Приложение отвечает за согласованную запись в соответствующие представления.

7. Постановка задачи

Рассматривается информационная система университета. Необходимо быстро получать расписание конкретной группы за период и занятия конкретного преподавателя. Запросы известны заранее, поэтому модель проектируется отдельно под каждый паттерн доступа.

Паттерн доступа	Частота	Требование
Расписание группы за дату/период	высокая	partition key = группа; сортировка по дате и времени
Занятия преподавателя за дату/период	высокая	отдельная таблица с partition key = преподаватель
Добавление занятия	средняя	запись в необходимые представления
Изменение аудитории	низкая/средняя	обновить соответствующие строки

8. Подготовка среды

Создайте учебный keyspace. Для локального одноузлового стенда используется SimpleStrategy; это решение предназначено только для лабораторной среды.

```
CREATE KEYSPACE IF NOT EXISTS lab6
WITH replication = {'class': 'SimpleStrategy', 'replication_factor': 1};
USE lab6;
```

Проверка:

```
DESCRIBE KEYSPACE lab6;
```

9. Демонстрационный пример

Запрос Q1: получить расписание одной группы за заданный период в хронологическом порядке.

```
CREATE TABLE schedule_by_group (
  group_id text,
  lesson_date date,
  lesson_time time,
  course_id text,
  course_name text,
  teacher text,
  room text,
  PRIMARY KEY ((group_id), lesson_date, lesson_time, course_id)
) WITH CLUSTERING ORDER BY (lesson_date ASC, lesson_time ASC, course_id ASC);
```

Здесь group_id - partition key. lesson_date, lesson_time и course_id - clustering columns. course_id добавлен в ключ для уникальности занятий, которые потенциально могут иметь одинаковые дату и время.

```
INSERT INTO schedule_by_group (group_id, lesson_date, lesson_time, course_id, course_name, teacher, room) VALUES
('IS-24-1','2026-10-08','09:00:00','NOSQL-301','NoSQL Technologies','A. Teacher','305');
INSERT INTO schedule_by_group (group_id, lesson_date, lesson_time, course_id, course_name, teacher, room) VALUES
('IS-24-1','2026-10-08','11:00:00','WEB-210','Web Development','B. Teacher','410');
INSERT INTO schedule_by_group (group_id, lesson_date, lesson_time, course_id, course_name, teacher, room) VALUES
('IS-24-1','2026-10-09','10:00:00','DB-205','Database Systems','C. Teacher','212');

SELECT * FROM schedule_by_group WHERE group_id='IS-24-1' AND lesson_date >= '2026-10-08' AND lesson_date <=
'2026-10-09';
```

Ожидаемый результат: три строки группы IS-24-1 в порядке даты и времени. Запрос начинается с равенства по partition key и использует последовательность clustering columns.

Изменение аудитории:

```
UPDATE schedule_by_group SET room='415' WHERE group_id='IS-24-1' AND lesson_date='2026-10-08' AND lesson_time='11:00:00' AND course_id='WEB-210';
```

Безопасное удаление одной тестовой строки:

```
DELETE FROM schedule_by_group WHERE group_id='IS-24-1' AND lesson_date='2026-10-09' AND lesson_time='10:00:00' AND course_id='DB-205';
```

10. Пошаговый порядок выполнения

Этап 1. Анализ требований

Определите роли пользователей, 5 основных запросов, частоту чтения/записи, ожидаемый объем и требования к порядку результатов.

Этап 2. Карта запросов

Для каждого запроса запишите точную форму: какие поля известны на входе, какие строки нужно вернуть, нужна ли сортировка или диапазон.

Этап 3. Выбор partition key

Для каждого запроса выберите partition key и объясните, почему он обеспечивает адресный доступ и приемлемое распределение нагрузки.

Этап 4. Выбор clustering columns

Определите порядок clustering columns исходя из сортировки и диапазонных условий.

Этап 5. Проектирование таблиц

Создайте минимум 2 таблицы, обслуживающие разные паттерны доступа. Не пытайтесь обслужить все запросы одной универсальной таблицей.

Этап 6. Тестовые данные

Добавьте не менее 20 осмысленных строк суммарно. Обеспечьте несколько значений partition key и несколько строк внутри каждой партиции.

Этап 7. Запросы

Выполните минимум 5 запросов, соответствующих карте доступа. Не используйте ALLOW FILTERING в обязательной части.

Этап 8. Изменение и удаление

Выполните одно UPDATE и одно DELETE с полным первичным ключом и проверьте результат.

Этап 9. Анализ партиций

Оцените, сколько строк потенциально окажется в одной партиции при росте системы в 10 и 100 раз. Выявите риск hot/large partition.

Этап 10. Вывод

Объясните, почему схема отличается от реляционной и какие компромиссы создает денормализация.

11. Шаблон проектирования запроса

Запрос	Известно на входе	Partition key	Clustering columns	Таблица
Q1: ...	...	...	...	...
Q2: ...	...	...	...	...
Q3: ...	...	...	...	...
Q4: ...	...	...	...	...
Q5: ...	...	...	...	...

12. Индивидуальные варианты

№	Предметная область	Сущности	5 обязательных запросов	Повышенная задача
1	Университет	группа, дисциплина, преподаватель, занятие	расписание группы; занятия преподавателя; занятия группы за период; занятие по дате/времени; дисциплины группы	оценить риск роста партиции расписания на несколько лет
2	Интернет-магазин	клиент, заказ, товар, статус	заказы клиента по дате; заказы по статусу; позиции заказа; заказы клиента за период; последние заказы	предложить bucket по месяцу при росте истории
3	Библиотека	читатель, книга, выдача, категория	выдачи читателя; выдачи по сроку возврата; история книги; выдачи за период; активные выдачи	оценить размер истории активного читателя
4	Медицинская система (учебные данные)	врач, кабинет, слот, прием	расписание врача; приемы пациента; слоты по дате; приемы врача за период; прием по времени	предложить безопасное временное bucket-разбиение
5	Служба доставки	курьер, заказ, зона, событие	заказы курьера; события заказа; доставки зоны; события за период; последние статусы	оценить рост событий одного заказа/курьера
6	Система бронирования	пользователь, ресурс, бронь, дата	брони пользователя; брони ресурса по дате; история брони; брони за период; активные брони	обосновать partition key для популярного ресурса
7	Социальная платформа	пользователь, публикация, событие, автор	публикации автора; события публикации; лента автора по времени; последние события; публикации за период	предложить time bucket для высокоактивного автора
8	Складской учет	склад, товар, движение, категория	движения товара; движения склада по времени; операции за период; история товара; последние операции	оценить hot partition крупного склада
9	Онлайн-обучение	курс, студент, урок,	активность студента;	предложить bucket

		активность	события курса; уроки курса; активность за период; последние действия	для массового курса
10	Мониторинг устройств	устройство, измерение, группа, время	измерения устройства; события группы; измерения за период; последние значения; события по времени	спроектировать дневной/часовой bucket для частой телеметрии

Для каждого варианта дополнительно обязательно: создать минимум 2 таблицы; определить обязательные поля и типы; выполнить INSERT, 5 SELECT, UPDATE и DELETE; сделать один аналитический расчет на основе полученных данных; обосновать модель и оценить распределение партиций.

13. Задания по уровням сложности

Уровень	Обязательные результаты	Максимум
Базовый	keyspace; 2 таблицы; корректные PRIMARY KEY; ≥20 строк; базовые SELECT/INSERT/UPDATE/DELETE	69
Средний	5 query-driven запросов; обоснование partition/clustering keys; диапазонные выборки; денормализация; анализ партиций	89
Повышенный	альтернативная модель, time bucketing или переработка ключа при росте нагрузки; сравнение компромиссов	100

14. Ожидаемые результаты и проверка

Успешная работа содержит воспроизводимые CQL-команды и показывает, что каждый обязательный запрос выполняется через таблицу, специально спроектированную под этот паттерн доступа. Студент должен уметь выполнить DESCRIBE TABLE, SELECT по partition key, диапазон по clustering column, UPDATE и DELETE и объяснить результат.

```
DESCRIBE TABLE schedule_by_group;
SELECT * FROM schedule_by_group WHERE group_id='IS-24-1';
```

15. Типичные ошибки

Ошибка	Последствие	Исправление
Проектирование от сущностей, а не запросов	нужные SELECT требуют сканирования	сначала сформулировать карту запросов
Случайный partition key	hot partition или неудобный доступ	оценить кардинальность и распределение
Одна таблица для всех запросов	ALLOW FILTERING и сложные обходы	создать отдельные query tables
Неверный порядок clustering columns	диапазонный запрос не соответствует ключу	согласовать порядок с WHERE/ORDER
Неограниченный рост партиции	большие партиции и деградация	добавить time bucket при необходимости
Механическое копирование нормализованной SQL-схемы	JOIN-подобные потребности	денормализовать под чтение
Использование ALLOW FILTERING как основного решения	непредсказуемая стоимость	перепроектировать таблицу
DELETE без полного понимания ключа	неожиданное удаление	проверить SELECT и полный ключ
Одинаковый partition key для огромного потока	горячая партиция	добавить обоснованное разбиение
Дублирование без стратегии записи	несогласованные представления	описать, какие таблицы обновляются вместе

16. Контрольные вопросы

1. Что означает query-driven design в Cassandra?
2. Какую роль выполняет partition key?
3. Чем clustering column отличается от partition key?
4. Как записывается составной PRIMARY KEY в CQL?
5. Почему запрос без partition key часто указывает на проблему модели?
6. Почему в Cassandra допустима денормализация?
7. Как порядок clustering columns связан с диапазонным запросом?
8. Что такое hot partition и чем она опасна?
9. Когда полезно time bucketing?
10. Почему хорошая Cassandra-модель может содержать несколько таблиц с дублирующимися данными?

17. Требования к отчету

- титульный лист, номер и точная тема;
- цель и индивидуальный вариант;
- описание предметной области и 5 паттернов доступа;
- таблица «запрос → partition key → clustering columns → таблица»;
- CQL определения keyspace и таблиц;
- тестовые данные и команды;
- скриншоты результатов каждого ключевого запроса с подписью;
- UPDATE и DELETE с проверкой;
- оценка размеров/распределения партиций;
- анализ денормализации и ограничений;
- ответы на контрольные вопросы;
- вывод.

18. Критерии оценивания

Критерий	Баллы
Анализ требований и паттернов доступа	10
Обоснование модели	10
Partition/clustering keys и структура таблиц	15
Корректность тестовых данных	10
Основные CQL-операции и запросы	20

Сложные запросы / анализ партиций	15
Анализ результатов	10
Оформление отчета	5
Защита	5
Итого	100

Полное выполнение означает корректное, воспроизводимое и аргументированное решение;
частичное - наличие работающей части при неполном обосновании или отдельных ошибках;
невыполнение - отсутствие результата либо схема, не поддерживающая обязательные запросы.

Шкала: 90–100 - отлично; 70–89 - хорошо; 50–69 - удовлетворительно; 0–49 - требуется повторное выполнение.

19. Вопросы для защиты

1. Почему вы выбрали именно этот partition key?
2. Какие строки попадут в одну партицию?
3. Почему clustering columns расположены именно в таком порядке?
4. Какой запрос обслуживает каждая таблица?
5. Почему вы допустили дублирование данных?
6. Как будет изменяться размер партиции при росте системы?
7. Где может возникнуть hot partition?
8. Почему вы не использовали ALLOW FILTERING?
9. Какую альтернативную модель можно предложить?
10. Что измените при росте нагрузки в 100 раз?

20. Необязательное задание повышенной сложности

Выберите наиболее быстро растущую таблицу варианта и разработайте альтернативу с time bucketing (например, год/месяц/день). Сравните исходную и новую модели по размеру партиции, количеству запросов для чтения периода, распределению нагрузки и сложности приложения. Дополнительное задание учитывается внутри существующих критериев; итог не превышает 100 баллов.

21. Источники

1. Силлабус дисциплины «Проектирование и применение NoSQL-технологий», 2026–2027: лекция № 6 и лабораторная работа № 6.
2. Apache Cassandra Documentation. Data modeling, CQL, partition keys and clustering columns. Официальная документация проекта Apache Cassandra. Дата обращения: 07.10.2026.
3. Apache Cassandra Documentation. CQL DDL/DML reference. Дата обращения: 07.10.2026.